Conceptos estadísticos básicos

Oct–Dic 2026

Curso de formación en evaluación de impacto

Ruta de la sesión

Parte 1

- Media y desviación estándar
- Muestreo aleatorio
- Error estándar

Parte 2.

- Prueba t
- Valor p
- Regresión lineal y pruebas t de los coeficientes

Todo este vocabulario se usará después para leer los resultados de herramientas de inferencia causal.

Media y desviación estándar

Notación: variables X y Y

Variable independiente (X)

Es la variable que se supone que **influye** en otra. Por ejemplo, la participación en el programa.

Variable dependiente (Y)

Es la variable que se busca **explicar**. También se llama variable de resultado.

Ejemplo: se quiere saber si las horas de sueño (X) afectan las notas de los estudiantes (Y).

Medida de tendencia central: la media

Definición

La **media** (o promedio) suma todos los valores de una variable y los divide por el número de observaciones.

$$\bar{x} = \frac{1}{n} \sum_{i=1}^{n} x_i$$

Ingreso mensual (USD) de 5 hogares: 300, 320, 350, 380, 1650.

La media es $\bar{x} = \frac{3000}{5} = 600$.

En evaluación de impacto, el efecto de un programa se estima comparando medias: la del grupo de tratamiento contra la del grupo de control.

Cuánto varían los datos: la desviación estándar

Definición

La **desviación estándar** (s) mide qué tan lejos están, en promedio, las observaciones respecto a su media.

$$s = \sqrt{\frac{1}{n-1}\sum_{i=1}^{n}(x_i - \bar{x})^2}$$

s pequeña

Los datos están concentrados alrededor de la media.

s grande

Los datos están muy dispersos alrededor de la media.

La desviación estándar describe la dispersión de los datos.

Muestreo aleatorio y error estándar

Muestreo y asignación aleatoria



Definición

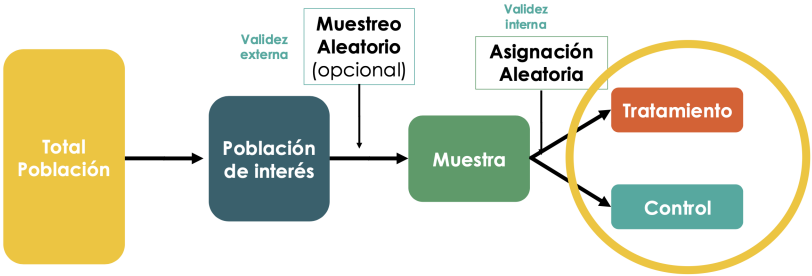
Proceso de seleccionar **al azar** una muestra de la población de interés, a partir de un marco muestral (la lista de unidades desde la cual se elige).

No confundir con la asignación aleatoria

El **muestreo** decide *quién entra en el estudio*. La **asignación** decide *quién recibe el programa y quién es control* entre los ya seleccionados.

Muestreo y asignación aleatoria

Muestreo Aleatorio vs. Asignación Aleatoria



En esta sesión veremos diferentes maneras para aleatorizar la asignación

Error estándar

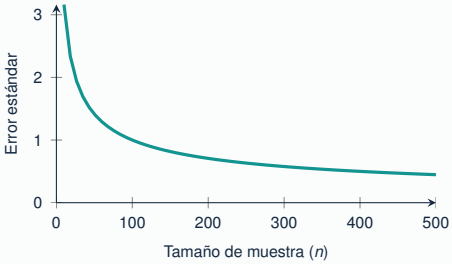
Definición

El **error estándar** (EE) de la media mide cuánto varía la media de una muestra a otra. Es la desviación estándar de las medias muestrales.

$$EE(\bar{x}) = \frac{s}{\sqrt{n}}$$

s	n	EE
10	25	2.0
10	100	1.0
10	400	0.5

Con muestras más grandes, el error estándar será menor.



Desviación estándar frente a error estándar

Desviación estándar (s)

Describe qué tan dispersos están **los datos individuales** en una muestra.

No disminuye necesariamente al aumentar n.

Error estándar (EE)

Describe qué tan precisa es **una estimación** (por ejemplo, la media).

Disminuye al aumentar n.

Pruebas de hipótesis

Prueba t y valor p

Prueba t de diferencia de medias

Definición

La **prueba t** compara la diferencia observada entre dos medias con el ruido esperado por azar (el error estándar de esa diferencia).

$$t = \frac{\bar{Y}_T - \bar{Y}_C}{EE}$$

Ejemplo

$\bar{Y}_T = 78$, $\bar{Y}_C = 74$, $s_T = s_C = 12$, $n_T = n_C = 100$.

$$EE = \sqrt{\tfrac{144}{100} + \tfrac{144}{100}} \approx 1.70 \quad t = \tfrac{4}{1.70} \approx 2.36$$

t es una razón entre señal (la diferencia) y ruido (el error estándar). Un t grande en valor absoluto indica que la diferencia es difícil de atribuir al azar.

Valor p

Definición

El **valor p** es la probabilidad de obtener una diferencia al menos tan grande (en valor absoluto) como la observada, **suponiendo que la hipótesis nula es cierta**.

Diferencias en disciplinas

Cada disciplina tiene sus propios estándares en torno a los valores p.

Regla de decisión

Se fija un nivel de significancia α antes del análisis (usualmente 0.05).

- Si $p < \alpha$: se rechaza H_0.
- Si $p \geq \alpha$: no se rechaza H_0.

Qué dice y qué no dice el valor p

Sí dice

Qué tan compatibles son los datos con la hipótesis nula. Un valor p pequeño indica que los datos serían poco esperables si la hipótesis nula fuese cierta.

No dice

- La probabilidad de que H_0 sea cierta.
- El tamaño ni la importancia del efecto.
- Que el impacto sea relevante para la política pública.

Un efecto puede ser estadísticamente significativo y, aun así, muy pequeño en términos prácticos. Siempre se debe reportar el tamaño del efecto junto con el valor p.

Hipótesis nula y alternativa

Un programa de refuerzo escolar se aplica a un grupo de tratamiento. Se observa que su puntaje promedio es 4 puntos mayor que el del grupo de control.

Hipótesis nula (H_0)

El programa **no tiene efecto**: la diferencia real entre las medias es cero.

$$H_0 : \mu_T - \mu_C = 0$$

Hipótesis alternativa (H_1)

El programa **sí tiene efecto**: la diferencia real es distinta de cero.

$$H_1 : \mu_T - \mu_C \neq 0$$

La pregunta es si una diferencia de 4 puntos es lo bastante grande para descartar que se deba solo al azar del muestreo.

Regresión lineal

Estimar relaciones y probar hipótesis

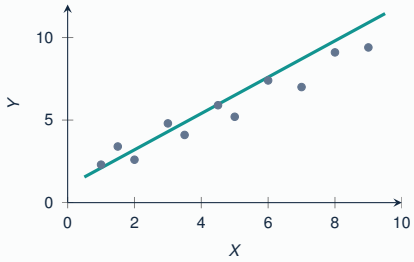
El modelo de regresión lineal

Definición

La regresión lineal describe cómo cambia, en promedio, la variable dependiente Y cuando cambia la variable independiente X.

$$Y_i = \beta_0 + \beta_1 X_i + \varepsilon_i$$

- β_0: valor esperado de Y cuando $X = 0$ (intercepto).
- β_1: cambio esperado en Y por cada unidad adicional de X (pendiente).
- ε_i: todo lo que afecta a Y y no está en el modelo (error).



Regresión con una variable de tratamiento

Modelo

Sea $T_i = 1$ si el individuo participa en el programa y $T_i = 0$ si es control:

$$Y_i = \beta_0 + \beta_1 T_i + \varepsilon_i$$

- β_0 = media del grupo de **control**: $\bar{Y}_C$.
- $\beta_0 + \beta_1$ = media del grupo de **tratamiento**: $\bar{Y}_T$.
- $\beta_1 = \bar{Y}_T - \bar{Y}_C$: la **diferencia de medias**.

En un RCT, $\hat{\beta}_1$ es la estimación del impacto del programa. Es la misma diferencia de medias de la prueba t, ahora dentro de una regresión.

Si $\bar{Y}_C = 74$ y $\bar{Y}_T = 78$, entonces $\hat{\beta}_0 = 74$ y $\hat{\beta}_1 = 4$.

Regresión con variables de control

Modelo

Se pueden añadir variables adicionales X_i (por ejemplo, edad o nivel educativo previo):

$$Y_i = \beta_0 + \beta_1 T_i + \gamma X_i + \varepsilon_i$$

Interpretación

β_1 es la diferencia esperada en Y entre tratamiento y control, **manteniendo constantes** las variables de control.

Para qué sirven

En un RCT, los controles ayudan a **reducir el error estándar** y a estimar el impacto con más precisión. En diseños no aleatorizados, no bastan por sí solos para garantizar causalidad.

Pruebas t en regresión lineal

Idea

Cada coeficiente tiene su propio error estándar. La prueba t contrasta si es distinto de cero:

$$H_0 : \beta_1 = 0 \qquad t = \frac{\hat{\beta}_1}{EE(\hat{\beta}_1)}$$

Resultado de la regresión del ejemplo

```
lm(puntaje ~ tratamiento, data = datos)
```

	Estimación	Error est.	Valor t	Valor p
Intercepto	74.00	1.20	61.7	< 0.001
Tratamiento	4.00	1.70	2.36	0.019

Como $p = 0.019 < 0.05$, se rechaza H_0: la diferencia de 4 puntos es estadísticamente significativa. Con varianzas iguales, coincide con la prueba t de diferencia de medias.

Resumen

Concepto	Qué responde
Media	¿Cuál es el valor típico de la variable?
Desviación estándar	¿Qué tan dispersos están los datos?
Muestreo aleatorio	¿Cómo elegimos a quiénes estudiar para representar a la población?
Error estándar	¿Qué tan precisa es la estimación?
Prueba t	¿La diferencia observada es grande frente al ruido?
Valor p	¿Qué tan esperable sería esta diferencia si el programa no tuviera efecto?
Regresión lineal	¿Cuál es la relación entre X y Y, y qué tan precisa es su estimación?

Gracias

Preguntas y comentarios